Düşük Dozlu Bilgisayarlı Tomografi (LDCT) Görüntü İyileştirme Çabalarının Kapsamlı Analizi: EEMKON Konferans Bildirisinden Q1 Seviyesi Dergi Makalesine Geçiş İçin Eleştirel ve Stratejik Yol Haritası

Tıbbi görüntüleme disiplininde, teşhis kalitesinden ödün vermeden hastaların maruz kaldığı iyonlaştırıcı radyasyon miktarını asgari düzeye indirmek, klinik araştırmaların temel itici güçlerinden biridir. Düşük Dozlu Bilgisayarlı Tomografi (LDCT) protokolleri, hasta güvenliğini sağlamada kritik bir rol oynamasına rağmen, X-ışını tüpü akımının (mAs) düşürülmesi doğal olarak dedektörlere ulaşan foton sayısını azaltmaktadır. Bu durum, "foton açlığı" (photon starvation) olarak bilinen fiziksel fenomene ve sinyal-gürültü oranının (SNR) dramatik bir şekilde düşmesine neden olmaktadır. Sonuç olarak, yeniden yapılandırılan (reconstructed) görüntülerde artan kuantum gürültüsü (Poisson dağılımı), elektronik gürültü (Gaussian dağılımı) ve çizgi (streak) artefaktları ortaya çıkmakta, bu bozulmalar da küçük lezyonların, mikro-kalsifikasyonların ve düşük kontrastlı yumuşak doku sınırlarının tespitini zorlaştırmaktadır.
Bu klinik ve teknik bağlamda sunulan "Low-Dose CT Image Enhancement using Pix2Pix and WGAN-GP" başlıklı EEMKON 2026 konferans bildirisi, üretken derin öğrenme algoritmalarının bu problemi çözmedeki potansiyelini araştıran temel (baseline) bir çalışma niteliği taşımaktadır.[1] Bildiride, tıbbi görüntü gürültüsü giderme problemi bir görüntüden görüntüye çeviri (image-to-image translation) görevi olarak formüle edilmiş ve bu amaçla Koşullu Üretken Çekişmeli Ağlar (cGAN) sınıfından Pix2Pix mimarisi kullanılmıştır.[1] Ağın üretici (generator) bileşeni olarak uzamsal detayları korumasıyla bilinen U-Net mimarisi, ayırt edici (discriminator) bileşeni olarak ise yerel yamalar üzerinde çalışan PatchGAN tercih edilmiştir.[1] Çalışmanın en çok vurgulanan yönü ise, GAN eğitiminde sıklıkla karşılaşılan kip çökmesi (mode collapse) ve eğitim kararsızlıklarını aşmak amacıyla standart Jensen-Shannon ıraksaması yerine Wasserstein mesafesini ve gradyan cezasını (WGAN-GP) kullanan bir kayıp fonksiyonunun ağa entegre edilmesidir.[1]
Çalışmanın klinik ve harici fantom veri setleri üzerindeki öncül sonuçları incelendiğinde, 37.75 dB Tepe Sinyal-Gürültü Oranı (PSNR) ve 0.8914 Yapısal Benzerlik İndeksi (SSIM) gibi nicel değerler raporlanmıştır.[1] Bu performans metrikleri, bir lisans bitirme projesi veya ulusal bir mühendislik konferansı için kabul edilebilir bir başlangıç noktası teşkil etse de, çalışmanın IEEE Transactions on Medical Imaging (TMI) veya Medical Image Analysis (MedIA) gibi Q1 çeyrekliğinde yer alan, etki faktörü yüksek ve alanının zirvesini belirleyen uluslararası dergilere sunulabilmesi için

mevcut durumunun çok ötesine geçmesi gerekmektedir. Bir akademik araştırma makalesinin Q1 dergilerde kabul görebilmesi için, halihazırda keşfedilmiş mimari blokların basit bir mühendislik entegrasyonundan ziyade, literatürdeki mevcut boşlukları dolduran, metodolojik olarak devrimsel veya alanın anlayışını kökten değiştiren derin bir bilimsel katkı sunması zorunludur.
Bu rapor, mevcut EEMKON bildirisindeki metodolojik altyapıyı, sunulan yeni genişletme tekliflerini (CBAM dikkat mekanizması entegrasyonu ve sıfırdan DDPM eğitimi) ve bu tekliflerin geçerliliğini tıbbi görüntü işleme literatürünün en güncel (2024-2026) doğruları ışığında acımasız bir eleştirel süzgeçten geçirmektedir. Rapor boyunca, mimari tasarımların teorik limitleri, değerlendirme metriklerinin klinik kör noktaları ve jeneratif modellerin en büyük tehlikesi olan "halüsinasyon" riski derinlemesine incelenecek ve çalışmayı üst düzey bir bilimsel yayına dönüştürecek kesin bir yol haritası sunulacaktır.

Temel Altyapının ve Bildiri Argümanlarının Eleştirel Analizi

EEMKON bildirisinin merkezinde yatan metodolojik tercihlerin ve bu tercihlerin literatürdeki yerinin doğru anlaşılması, gelecekteki iyileştirmelerin yönünü belirlemek açısından hayati öneme sahiptir. Bildirinin giriş ve yöntem bölümleri incelendiğinde, Pix2Pix mimarisi ile WGAN-GP kayıp fonksiyonunun "doğrudan entegrasyonunun daha önce keşfedilmediği" (remains unexplored) ve bu durumun özgün bir bilimsel katkı (novel contribution) oluşturduğu iddia edilmektedir.[1] Ancak, tıbbi görüntü işleme alanındaki üretken modellerin tarihsel gelişimi göz önüne alındığında, bu iddia son derece zayıf ve literatürün derinliğinden uzaktır.
Generative Adversarial Networks (GAN) mimarisinin 2014 yılında Goodfellow ve arkadaşları tarafından tanıtılmasının ardından, orijinal GAN formülasyonunun eğitim dinamiklerinin kararsız olduğu ve kip çökmesine yatkın olduğu kısa sürede anlaşılmıştır.[1] Bu kararsızlık, üreticinin ve ayırt edicinin optimize etmeye çalıştığı fonksiyonların yapısından kaynaklanmaktaydı. Bu sorunu çözmek için 2017 yılında Gulrajani ve arkadaşları, ayırt edicinin gradyan normuna bir ceza terimi ekleyerek 1-Lipschitz sürekliliğini zorlayan WGAN-GP (Wasserstein GAN with Gradient Penalty) mimarisini literatüre kazandırmıştır.[1] Tıbbi görüntüleme araştırmacıları, bu stabilizasyon tekniğini LDCT gürültü giderme problemlerine uyarlamakta gecikmemiştir. Örneğin, Yang ve arkadaşları (2018), Wasserstein mesafesi ile VGG tabanlı algısal kaybı (perceptual loss) birleştirerek LDCT görüntülerini iyileştirmiş ve WGAN'ın tıbbi çeviri görevlerindeki üstünlüğünü kanıtlamıştır.[1] Benzer şekilde Li ve arkadaşları (2021) ve literatürdeki sayısız çalışma, WGAN-GP'yi farklı üreteç yapılarıyla birleştirerek bu alanı doyum noktasına ulaştırmıştır.[1]
Dolayısıyla, 2026 yılında bir Q1 dergi hakemi paneline "Pix2Pix ile WGAN-GP'yi birleştirdik" argümanıyla çıkmak, "tekerleği yeniden icat etme" çabası olarak görülecek ve doğrudan ret (desk-reject) ile sonuçlanacaktır. Q1 dergiler, halihazırda kanıtlanmış ve endüstri standardı haline gelmiş iki eski metodun (2017 çıkışlı Pix2Pix ve yine 2017 çıkışlı WGAN-GP) uç uca eklenmesini bir "bilimsel yenilik" olarak kabul etmez. Bu tür bir yaklaşım, ancak yeni bir matematiksel optimizasyon stratejisi, yeni bir fiziksel bilgi entegrasyonu veya tamamen yeni bir ağ topolojisi önerildiğinde anlam kazanır. Ayrıca, PatchGAN tabanlı bir ayırt edici ile piksel bazlı L1 kaybını birleştiren klasik Pix2Pix mimarisi, global bağlamı algılamakta yetersiz kaldığı için, anatomik

yapıların bütünlüğünü korumada modern yaklaşımların (örneğin Difüzyon veya Durum Uzay Modellerinin) gerisinde kalmaktadır. Bu nedenle, çalışmanın mevcut altyapısı sağlam bir mühendislik uygulaması olsa da, akademik bir yayın için sadece veri ön işleme ve ardışık düzen (pipeline) kurma pratiği olarak değerlendirilmelidir.

Birinci Metodolojik Teklifin Değerlendirilmesi: Dikkat Yönlendirmeli (Attention-Guided) GAN ve CBAM Entegrasyonunun Yetersizliği

Araştırmanın makaleye dönüştürülmesi için sunulan ilk genişletme teklifi, mevcut U-Net jeneratörünün atlama bağlantılarına (skip connections) Uzamsal Dikkat Kapıları (Spatial Attention Gates) veya Evrişimli Blok Dikkat Modülü (Convolutional Block Attention Module - CBAM) entegre edilmesini içermektedir. Bu teklifin teorik dayanağı, standart CNN tabanlı ağların tüm uzamsal bölgelere ve kanallara eşit ağırlık vermesi, bu nedenle ağın klinik olarak önemsiz arka plan dokularına gereksiz işlem gücü harcarken ince kılcal damarlar, lezyon sınırları ve düşük kontrastlı anatomik detaylar gibi tanısal önemi yüksek yapıları gözden kaçırma riskidir. CBAM gibi mekanizmaların ağa entegre edilmesiyle, modelin nerede (uzamsal dikkat) ve neye (kanal dikkati) odaklanması gerektiğini öğrenmesi ve böylece gürültü ile gerçek anatomik yapı arasındaki ayrımı daha hassas bir şekilde yapması hedeflenmektedir.

Metodolojik düzeyde bu gerekçelendirme tamamen mantıklı ve doğrudur. Dikkat mekanizmaları, ağın temsili kapasitesini (representational capacity) artırarak özellik çıkarım sürecini (feature extraction) zenginleştirir. Ancak, bu stratejinin bir Q1 dergide yayımlanabilir özgünlükte bir bilimsel katkı sunup sunmadığı sorulduğunda, verilecek cevap kesin ve net bir hayırdır. Tıbbi görüntü işleme literatürünün 2024 ve 2025 yılları arasındaki seyri incelendiğinde, U-Net, GAN ve CBAM/Dikkat Kapıları kombinasyonunun defalarca araştırılmış, farklı veri setlerinde sınanmış ve çoktan tüketilmiş bir paradigma olduğu açıkça görülmektedir. Örneğin, Yu ve arkadaşları tarafından 2025 yılında sunulan "Low-Dose CT Image Denoising Combining U-Net Based on the CBAM Attention Mechanism with Generative Adversarial Networks" başlıklı çalışma, tam olarak öğrencinin önermiş olduğu bu spesifik mimariyi (U-Net + CBAM + GAN) literatüre kazandırmıştır.[5] Bu çalışma, CBAM modüllerinin U-Net tabanlı bir GAN ağına entegre edilmesinin LDCT gürültü giderme üzerindeki etkilerini halihazırda incelemiş ve yayınlamıştır.[5] Teklif edilen metodolojinin, zaten yayımlanmış bir çalışmanın tekrarı (replication) olmaktan öteye gidemeyeceği aşikardır.

Bunun ötesinde, dikkat mekanizmalarını GAN'lar ile birleştiren yaklaşımlar çok daha karmaşık ve gelişmiş mimarilere evrilmiştir. 2025 yılında tanıtılan De-TransGAN (Denoising Transformer-Augmented Generative Adversarial Network) mimarisi, standart CNN tabanlı dikkat modellerinin sınırlarını aşarak, evrişimli katmanları Transformer blokları ile entegre etmiştir.[7] De-TransGAN, yerel doku detaylarını yakalamak için CNN'leri kullanırken, uzun menzilli anatomik bağımlılıkları (long-range dependencies) modellemek için Vision Transformer (ViT) bileşenlerinden faydalanır ve bu yapıyı diagnostik açıdan kritik yapılara yönlendirmek (guide) için CBAM tabanlı kanal-uzamsal dikkat modüllerini kullanır.[7] De-TransGAN'ın eğitim stabilitesi yine WGAN-GP ile sağlanmış, optimizasyon ise L1 kaybı, SSIM kaybı ve VGG algısal kaybını

(perceptual loss) içeren kompozit bir fonksiyonla gerçekleştirilmiştir.[7] Bu SOTA mimari, TCIA LDCT ve AAPM Mayo Clinic Grand Challenge veri setleri üzerinde 44.92 dB PSNR ve 0.9801 SSIM gibi olağanüstü yüksek metrikler elde etmiştir.[7]

Bir diğer çarpıcı örnek ise 2026 yılında yayımlanan RDBCycleGAN-CBAM çalışmasıdır.[9] Bu model, eşleşmemiş (unpaired) çeyrek dozlu BT görüntülerini iyileştirmek için döngüsel tutarlılık (cycle-consistency) tabanlı bir GAN mimarisi kurmuş, bu yapıyı Kalıntı Yoğun Bloklar (Residual Dense Blocks - RDB) ve CBAM ile güçlendirerek yapısal detayların korunmasında istatistiksel olarak anlamlı bir üstünlük sağlamıştır.[9]

Mevcut EEMKON bildirisini geliştirmek için sunulan CBAM eklentisinin, bahsi geçen De-TransGAN ve RDBCycleGAN-CBAM gibi karmaşık, hibrit ve son derece optimize edilmiş modern mimarilerin yanında oldukça ilkel ve yüzeysel (incremental) bir katkı olarak kalacağı ortadadır. Literatürde halihazırda U-Net + CBAM + GAN modellerinin performansı ve sınırları biliniyorken, aynı kurguyu benzer veri setleri (NIH-AAPM-Mayo) üzerinde tekrar uygulayıp sunmak, araştırma kalitesi ve özgünlük açısından geçerli bir Q1 stratejisi değildir.

Evrişimli Sinir Ağlarında (CNN) Uzamsal Bağlam ve Algı Alanı Sınırları

CBAM eklentisinin neden Q1 dergilerin beklentilerini karşılayamayacağının altında yatan bir diğer faktör, geleneksel Evrişimli Sinir Ağlarının (CNN) mimari kısıtlamalarıdır. U-Net gibi CNN tabanlı mimariler, yerel özellikleri (local features) çıkarmada mükemmel bir iş çıkarsalar da, sabit boyutlu evrişim çekirdekleri (convolutional kernels) nedeniyle ağın algı alanı (receptive field) doğası gereği sınırlıdır.[7] CBAM veya Uzamsal Dikkat Kapıları (Attention Gates) bu sorunu hafifletmeye çalışarak önemli özellikleri vurgulasa da, ağın görüntü üzerindeki çok uzak pikseller arasındaki ilişkileri doğrudan ve global olarak modellemesini sağlayamaz.

Tıbbi görüntülemede, özellikle organ sınırlarının, geniş damar ağlarının veya dağınık lezyon yapıların geriçatımı (reconstruction) söz konusu olduğunda, global uzamsal bağlamın (global spatial context) anlaşılması hayati öneme sahiptir.[7] CNN'lerin bu lokalite (locality) önyargısı, gürültü giderme işlemi sırasında geniş ve yumuşak doku geçişlerinde asılsız dokuların (artifacts) oluşmasına veya modelin anatomik yapıların genel morfolojik bütünlüğünü bozmasına neden olabilir. Bu nedenle, 2025 ve 2026 yıllarında SOTA standartları, uzun menzilli bağımlılıkları modelleyebilen mimarilere, özellikle Transformer'lara ve Durum Uzay Modellerine (State Space Models) kaymıştır.[11] Sadece eski nesil bir CNN'in üzerine CBAM yaması yapmak, problemin fiziksel ve mimari kök nedenlerine inmekten ziyade yüzeysel bir müdahale olarak kalacaktır.

Aşağıdaki tablo, öğrencinin önerisi ile mevcut literatürdeki benzer ve daha gelişmiş mimariler arasındaki metodolojik çakışmaları ve kalite farklarını özetlemektedir:

Çalışma / Öneri	Temel Üreteç (Generator) Mimarisi	Kullanılan Dikkat Mekanizması	Eğitim / Optimizasyon	Bilimsel Özgünlük Değerlendirmesi
Öğrencinin CBAM Teklifi	Pix2Pix (U-Net)	CBAM / Spatial Attention Gates	WGAN-GP + L1	**Yetersiz ve Tüketilmiş.** Halihazırda yayınlanmış

				çalışmaların doğrudan tekrarı.
Yu et al. (2025) [5]	U-Net	CBAM	Adversarial + Perceptual	U-Net ve CBAM kombinasyonunun LDCT için literatürdeki spesifik karşılığı.
De-TransGAN (2025) [7]	Transformer (ViT) + CNN Hibrid	CBAM (Kanal ve Uzamsal)	WGAN-GP + L1 + VGG + SSIM	Kapsamlı SOTA. CNN'lerin lokal sınırlarını aşmak için ViT kullanımı.
RDBCycleGAN (2026) [9]	CycleGAN + RDB	CBAM	LSGAN + Döngüsel Tutarlılık	Eşleşmemiş (unpaired) veriler için SOTA. Yüksek performanslı yapısal koruma.

İkinci Metodolojik Teklifin Değerlendirilmesi: GAN ve SOTA Difüzyon (DDPM) Kıyaslamasının Analizi

Genişletme stratejisinin ikinci aşamasında, salt bir GAN tabanlı çözüm sunmak yerine, medikal görüntülemede mevcut SOTA olarak kabul edilen Gürültü Giderme Difüzyon Olasılıksal Modelleri (Denoising Diffusion Probabilistic Models - DDPM) mimarisinin aynı veri setinde sıfırdan eğitilmesi ve performansının (PSNR, SSIM ve Algısal Kayıp/LPIPS metrikleriyle) WGAN-GP ile stabilize edilmiş Dikkat Yönlendirmeli GAN modeliyle karşılaştırılması önerilmektedir. Ayrıca, makalenin ana konseptinin "GAN halüsinasyonlarına karşı Difüzyon modellerinin yapısal doğruluğu" ekseninde konumlandırılması hedeflenmektedir.
Bu teklif, CBAM eklentisinden çok daha güçlü bir akademik içgörü barındırmaktadır ve yazarın tıbbi yapay zeka alanındaki güncel kaygıları (halüsinasyon riski, yapısal doğruluk, difüzyon modellerinin yükselişi) doğru okuduğunu göstermektedir. Difüzyon modelleri, karmaşık veri dağılımlarını öğrenme yetenekleri, kararlı eğitim dinamikleri ve GAN'ların temel sorunu olan kip çökmesi (mode collapse) eğiliminden bağımsız olarak yüksek sadakatli (high-fidelity) veri üretebilmeleri sayesinde, tıbbi görüntü sentezi ve restorasyonunda son yıllarda devrim yaratmıştır.[13] Markov zinciri tabanlı ileri (forward) ve ters (reverse) difüzyon süreçleri, görüntü detaylarının ve ince anatomik yapıların korunmasında üstün performans göstermelerini sağlar.[14]
Ancak, önerilen "DDPM'i sıfırdan eğitme ve kıyaslama" planı, Q1 seviyesinde bir makalenin ana omurgasını oluşturmak için hem teorik hem de pratik açıdan ciddi yetersizlikler ve yanlış anlamalar barındırmaktadır.

Kıyaslama (Benchmark) Çalışmalarının Yayınlanabilirlik Sınırları

Salt bir "A Modeli (GAN) ile B Modelinin (DDPM) aynı veri seti üzerinde kıyaslanması", yeni ve çığır açıcı bir algoritma veya teorik bir bulgu sunmadığı sürece, Q1 dergiler tarafından genellikle bir

"teknik inceleme" (technical report) veya "anket" (benchmark/survey) olarak değerlendirilir. Öğrencinin geliştirdiği model (U-Net + CBAM) literatürde çoktan bilinen bir yapı olduğundan, bu modeli standart bir DDPM ile kıyaslamak alana yeni bir bilimsel katkı sunmaz. Bilimsel makalelerden beklenen, sadece iki modeli yarıştırmak değil, mevcut modellerin temel matematiksel veya fiziksel eksikliklerini tespit ederek bu sorunları çözen yeni bir mimari veya paradigma ortaya koymaktır.

Standart DDPM Mimarilerinin Klinik Uygunsuzluğu ve Hesaplama Maliyeti

Öğrencinin "sıfırdan eğiteceğini" belirttiği standart DDPM mimarisi (Ho et al., 2020 tabanlı piksel uzayı difüzyon modelleri), günümüz medikal görüntüleme camiasında pratik klinik kullanım için uygun kabul edilmemektedir. Standart bir difüzyon modelinin görüntü sentezlemesi veya gürültü gidermesi için yüzlerce, bazen binlerce zaman adımından (timesteps) oluşan iteratif bir ters difüzyon sürecini tamamlaması gerekir.[15] Bu iteratif doğa, standart bir BT hacminin (volume) işlenmesinin saniyeler değil, dakikalar hatta binlerce saniye sürmesine yol açar.[17]
2024 ve 2025 yıllarında yayımlanan SOTA difüzyon makaleleri, bu iteratif yükü ortadan kaldıran çözümlere odaklanmaktadır. Örneğin:

- **Latent Diffusion Models (LDM):** Hesaplama maliyetini düşürmek ve çıkarım (inference) hızını artırmak için difüzyon sürecini yüksek çözünürlüklü piksel uzayında değil, algısal olarak optimize edilmiş düşük boyutlu bir gizli uzayda (latent space) gerçekleştiren mimariler geliştirilmiştir.[17]
- **Cold Diffusion ve CoreDiff:** 2024 yılında IEEE TMI'da yayımlanan CoreDiff (Contextual Error-Modulated Generalized Diffusion Model) çalışması, standart Gaussian gürültüsü ekleme/çıkarma işlemi yerine, BT bozulma sürecinin fiziksel dinamiklerini taklit eden ve bilgilendirici LDCT görüntülerini difüzyonun başlangıç noktası olarak kullanarak örnekleme (sampling) adım sayısını dramatik ölçüde azaltan "Cold Diffusion" tabanlı bir model önermiştir.[16]
- **FoundDiff ve Doz-Anatomi Farkındalığı:** 2025 yılında sunulan FoundDiff modeli, difüzyon ağını belirli bir doz seviyesine aşırı uydurmak yerine, Kontrastlı Dil-Görüntü Ön Eğitimi (CLIP) benzeri (DA-CLIP) bir modül kullanarak ağın farklı doz seviyelerine ve anatomik bölgelere adaptif olarak tepki vermesini sağlayan jeneralize edilebilir bir temel difüzyon modeli (foundational diffusion model) kurmuştur.[20]
- **Tutarlılık Modelleri (Consistency Models):** Poisson Flow Consistency Models (PFCM) gibi yaklaşımlar, yüzlerce iterasyon yerine tek adımlı (single-step) veya çok az adımlı difüzyon örneklemeleri geliştirerek klinik uygulanabilirlik engelini aşmaya çalışmaktadır.[22]

Dolayısıyla, eğer çalışmaya bir difüzyon modeli entegre edilecekse, bu "standart bir DDPM'in sıfırdan eğitilmesi" şeklinde olamaz. Klasik DDPM, 2026 yılı itibarıyla hantal ve modası geçmiş bir temel (baseline) olarak kabul edilir. Q1 hakemleri, hesaplama açısından pratik olmayan bir modeli kıyaslama noktası olarak almayı, klinik gerçeklikten kopuk bir deney tasarımı olarak değerlendireceklerdir. Yapılması gereken, LDM veya CoreDiff gibi modern, hızlı ve bağlam farkındalığına sahip SOTA difüzyon mimarilerinden birinin (tercihen resmi açık kaynak kodlarıyla) referans olarak kullanılmasıdır.

Difüzyon ve GAN Kıyaslamasında Doğru Strateji

"GAN halüsinasyonlarına karşı Difüzyon modellerinin yapısal doğruluğu" fikri güçlü bir temadır. GAN'lar, özellikle aşırı düzleştirme (oversmoothing) veya eğitim verisindeki dominant özelliklere aşırı yakınsama (mode collapse) eğilimi nedeniyle gerçekte var olmayan dokular üretebilirken, Difüzyon modelleri olasılıksal doğaları gereği anatomik bütünlüğü çok daha iyi koruma eğilimindedir.[14] Ancak, difüzyon modelleri de halüsinasyonlara karşı tamamen bağışık değildir; özellikle veri uyumsuzluğu (domain shift) durumlarında veya yanlış şartlandırma (conditioning) altında gerçekdışı yapılar oluşturabilirler.[23] Bu nedenle, makalenin ana iddiası "Difüzyon halüsinasyon yapmaz, GAN yapar" şeklinde basite indirgenmemeli; bunun yerine her iki mimarinin istatistiksel sapmaları, yapısal koruma indeksleri ve fiziksel tutarlılıkları derinlemesine, nicel metriklerle analiz edilmelidir.

Gerçek State-of-the-Art (SOTA) Hangi Yönde İlerliyor? (2025-2026 Q1 Dergi Trendleri)

Mevcut öğrenci projesini sıradan bir tez çalışmasından çıkarıp ses getirecek bir akademik yayına dönüştürmek için, 2025 ve 2026 yıllarının hakim mimari paradigmalarını anlamak zorunludur. Günümüz literatürü incelendiğinde, klasik CNN'lerin (U-Net) algı alanı kısıtlamalarının ve Vision Transformer'ların (ViT) aşırı bellek tüketimi ve yüksek hesaplama karmaşıklığı (karekod/quadratic complexity) sorunlarının, yerini tamamen yeni bir yaklaşıma bıraktığı görülmektedir: **Seçici Durum Uzay Modelleri (Selective State Space Models) ve Mamba Mimarisi.**

Mamba ve Durum Uzay Modellerinin (SSM) Tıbbi Görüntülemedeki Devrimi

Durum Uzay Modelleri (SSM'ler), zaman serilerinden ve dil modellemesinden elde edilen prensipleri görsel veriye uygulayan, uzun menzilli bağlamı (long-range context) yakalamada mükemmel performans gösterirken hesaplama karmaşıklığını lineer (linear complexity) düzeyde tutan yeni nesil yapay zeka mimarileridir.[25] Tıbbi görüntülemede Mamba mimarisinin yükselişi, 2025 yılının en belirgin Q1 dergi trendlerinden biridir.
Mamba tabanlı modeller, BT kesitleri gibi yüksek çözünürlüklü ve detaylı görüntüleri tararken, dinamik olarak modüle edilmiş parametreler ve seçici tarama mekanizmaları (selective scanning mechanisms) kullanarak bilginin hem global olarak yayılmasını hem de yerel sınırların (lezyonlar, organ geçişleri) kesin olarak korunmasını sağlar.[26] Bu durum, LDCT gürültü giderme probleminde Mamba'yı geleneksel U-Net + CBAM tasarımlarının fersah fersah önüne geçirmektedir. Literatürde Mamba'nın LDCT gürültü giderme için kullanımını inceleyen çığır açıcı makaleler halihazırda yayımlanmaya başlamıştır:

1. CT-Mamba (2025) [11]: CT-Mamba, CNN'lerin yerel özellik çıkarma yetenekleri ile Mamba'nın uzun menzilli bağımlılıkları modelleme gücünü birleştiren hibrid bir Durum Uzay Modelidir. Standart Mamba dizilerinin 2D görüntülerde uzamsal kopukluklara yol açabilmesi sorununu çözmek için yenilikçi bir "Uzamsal Uyumlu Z-şekilli Tarama (Spatially Coherent Z-shaped Scanning)" şeması geliştirmiştir.[11] Bu sayede, pikseller arasındaki mekansal

sürekliliği sağlayarak gürültüyü son derece etkili bir şekilde bastırmış ve kılcal detayları korumuştur.[11]

2. DenoMamba (2025) [29]: DenoMamba, LDCT gürültü giderme görevinde durum uzay modellemesini kullanarak CT görüntülerindeki kısa ve uzun menzilli bağlamsal bağımlılıkları aynı anda ve verimli bir şekilde çözen kaskad (cascaded) bir mimari sunmuştur. Uzamsal bağlamı kodlayan "Uzamsal SSM Modülleri" ile kanal bağlamını kodlayan geçitli evrişim ağlarından (gated convolution network) oluşan "Kanal SSM Modüllerini" aynı anda (FuseSSM blokları) kullanır.[29] DenoMamba, %25 doz azaltma senaryolarında SOTA CNN ve Transformer modellerini sırasıyla 1.6 dB PSNR ve %1.7 SSIM farkıyla geride bırakmıştır.[29]
3. LangMamba (2025) [33]: Görsel-dil modellerini (Vision-Language Models) ve semantik yönlendirmeyi Mamba ile birleştiren bu çerçeve, BT görüntülerindeki dilsel semantiği bir VQGAN benzeri kodlayıcı aracılığıyla gizli uzaya entegre ederek, LDCT iyileştirme sürecini çok daha anlamlı ve klinik yapıları koruyacak şekilde yönlendirmiştir.[33]

Jeneratör Mimarisinde Radikal Bir Değişim İhtiyacı

Öğrencinin projesini kurtarabilmesi ve Q1 dergi hedefine ulaşabilmesi için yapması gereken hamle, U-Net ağına basit bir CBAM eklemek yerine, Pix2Pix altyapısındaki jeneratör ağını **Hibrid bir CNN-Mamba** veya **Saf Mamba (U-Mamba/VSSM)** mimarisine yükseltmektir. Eğer mevcut WGAN-GP kodu ve veri ön işleme (preprocessing) süreçleri başarılı bir şekilde çalışıyorsa, öğrenci doğrudan jeneratör modülündeki standart evrişimli kodlayıcı-kod çözücü (encoder-decoder) yapılarını çıkarıp, yerlerine açık kaynaklı Mamba bloklarını (örneğin Visual State Space - VSS blokları) yerleştirerek **"Mamba-WGAN"** veya **"State-Space GAN"** adını verebileceği devrimsel bir mimari kurgulayabilir. Mamba'nın difüzyon modellerinden daha hızlı olması ve Transformer'lardan daha az bellek tüketmesi, bu mimariyi difüzyon modellerine (DDPM/CoreDiff) karşı "hem hızlı hem de SOTA kalitesinde" bir alternatif olarak konumlandırmak için mükemmel bir zemin hazırlayacaktır.

Fizik Kılavuzlu Öğrenme (Physics-Guided Learning) ve Optimizasyon Kayıpları

Mimari değişimin yanı sıra, Q1 dergilerde kabul gören makalelerin bir diğer ortak özelliği, tıbbi görüntüleme probleminin ardındaki fiziksel doğayı derin öğrenme optimizasyon sürecine dahil etmeleridir (Physics-Informed/Physics-Guided Deep Learning). EEMKON bildirisinde model, yalnızca Piksel bazlı L1 kaybı (gerçek ile üretilen görüntü arasındaki mutlak piksel farkı) ve WGAN-GP (dağılımsal çekişmeli kayıp) kullanılarak eğitilmektedir.[1] Ancak BT gürültüsü basit bir Gaussian dağılımı değildir; dedektör donanımı, hastanın X-ışınını absorbe etme oranı ve filtrelenmiş ters izdüşüm (Filtered Back-Projection - FBP) veya yinelemeli (Iterative) algoritmaların oluşturduğu karmaşık bir uzamsal ve istatistiksel dağılıma sahiptir.[23]

L1, SSIM ve Algısal (Perceptual) Kayıpların Yetersizliği

- **L1/L2 Kaybı:** Görüntüdeki yüksek frekanslı ince detayları (damarlar, mikrokalsifikasyonlar)

korumakta başarısızdır ve sıklıkla aşırı pürüzsüzleşmiş (blurry/oversmoothed) görüntüler üretir.

- **VGG / Algısal (Perceptual) Kayıp:** ImageNet gibi doğal görüntü veri setleri üzerinde eğitilmiş VGG-16/19 ağlarından çıkarılan özelliklerin mesafesini ölçer.[7] İnsan gözüne estetik olarak daha hoş gelen ve gerçekçi dokular üretmesine yardımcı olsa da, doğal görüntüler ile tıbbi anatomik yapılar arasındaki keskin anlamsal farklar nedeniyle tıbbi bağlamda her zaman güvenilir sonuçlar vermez.[7]
- **Düşük Doz Fiziğinin Göz Ardı Edilmesi:** Geleneksel modeller, X-ışını foton istatistiklerini dikkate almadığı için üretilen görüntünün gürültü yapısı tamamen "plastik" veya "doğal olmayan" bir dokuya bürünebilir. Radyologlar bu sentetik görünümü sevmezler çünkü dokunun doğal heterojenliği silinmiş olur.

Gürültü Güç Spektrumu (Noise Power Spectrum - NPS) Kaybı Çözümü

Öğrenci, kayıp fonksiyonunu (loss function) fiziksel olarak anlamlı hale getirmek için CT-Mamba çalışmasında (2025) ustalıkla kullanılan bir yöntemi benimseyebilir: **Mamba-driven Deep NPS loss (Gürültü Güç Spektrumu Kaybı)**.[11] Gürültü Güç Spektrumu (NPS), bir BT sisteminin ürettiği gürültünün frekans bileşenlerini ve uzamsal korelasyonunu karakterize eden temel bir fiziksel metriktir.[35]
Eğer ağın optimizasyon hedefine, üretilen görüntünün gürültü spektrumu ile hedef tam dozlu (NDCT) görüntünün gürültü spektrumu arasındaki farkı minimize eden bir "Deep NPS Kaybı" eklenirse, model sadece piksellerin yerini doğru tahmin etmekle kalmaz, aynı zamanda görüntünün arka plan dokusunu (texture) da fiziksel olarak NDCT ile aynı karaktere büründürür.[11]
Bu "Fizik-Kılavuzlu" optimizasyon yaklaşımı, hakemlerin aradığı "metodolojik yenilik" ve "klinik anlayış" kriterlerini fazlasıyla karşılayacak ve standart Pix2Pix/GAN yaklaşımlarını radikal bir şekilde geliştirecektir.

Değerlendirme Paradigmasının Değişimi: Klinik Anlamlılık ve Halüsinasyon Riski

Bir tıp mühendisliği çalışmasını Q1 düzeyine çıkaran en kritik bölüm, sonuçların sadece metriklerle değil, klinik doğrulukla nasıl ispatlandığıdır. EEMKON bildirisi ve öğrencinin önerisi, başarıyı büyük ölçüde PSNR, SSIM ve Algısal Kayıp (LPIPS) skorları üzerinden tanımlamaktadır.[1]
Ancak 2025-2026 yıllarında, PSNR ve SSIM'in klinik tanı açısından güvenilmezliği genel kabul gören bir gerçektir.

PSNR, SSIM ve LPIPS'in Kör Noktaları

- **PSNR ve SSIM:** Bu metrikler piksellerin matematiksel hizalanmasına dayanır. Görüntü aşırı derecede düzleştirildiğinde (blurry), gürültü tamamen yok olduğu için PSNR skoru suni olarak yüksek çıkabilir.[35] Daha da tehlikelisi, bir yapay zeka modeli çok küçük boyutlu kritik bir kanser nodülünü "gürültü" zannedip sildiğinde, bu küçük piksel kümesinin kaybolması PSNR ve SSIM skorlarında istatistiksel olarak görünmezdir. Görüntü matematiksel olarak "yüksek kaliteli" sayılırken, klinik olarak "ölümcül hatalı" olabilir.[36]

- **LPIPS (Learned Perceptual Image Patch Similarity):** Öğrencinin kullanmayı planladığı LPIPS, insan algısına daha yakın bir değerlendirme sunarak, yamalar (patches) arasındaki derin özellik farklılıklarını ölçer.[37] GAN tabanlı modellerin ürettiği kip çökmesi veya gerçekçilikten uzak dokuları PSNR'a göre daha iyi yakalar.[37] Ancak LPIPS de temelini ImageNet özelliklerinden aldığı için, spesifik tıbbi lezyonların morfolojik doğruluğunu (örneğin bir akciğer nodülünün spiküle kenarları) doğrudan değerlendirme kapasitesine sahip değildir.[38]

Halüsinasyon Riski ve "DREAM Raporu" Standardı

Yapay zeka kaynaklı halüsinasyonlar, nükleer tıp ve BT görüntülemede en acil çözülmesi gereken güvenlik krizlerinden biridir. 2025 yılında yayımlanan ve medikal görüntülemede AIGC (Yapay Zeka Üretimli İçerik) uygulamaları için uluslararası bir konsensüs ve standart belirlemeyi amaçlayan **DREAM Raporu** (On Hallucinations in Artificial Intelligence–Generated Content for Nuclear Medicine Imaging), halüsinasyonları şu şekilde tanımlar: "Görsel olarak son derece gerçekçi ve makul görünen ancak anatomik veya işlevsel gerçekten sapan yapay zeka uydurması anormallikler veya artefaktlar".[39]
GAN'lar ve Difüzyon modelleri doğaları gereği "gerçekçi görünmek" üzere eğitildiklerinden, eğitim verisindeki dağılımlara dayanarak bir bölgeyi onarmaya çalışırken oraya fizyolojik olmayan (unphysical) yapılar ekleyebilir veya patolojik dokuları tamamen normal dokularla değiştirebilirler.[14] DREAM raporu, halüsinasyonları değerlendirmek için PSNR/SSIM gibi geleneksel metriklerin tamamen yetersiz olduğunu vurgulamakta ve çok aşamalı, kapsamlı bir test çerçevesi önermektedir.[39] Eğer öğrenci Q1 dergilerde (özellikle IEEE TMI veya MedIA) bir GAN veya Difüzyon makalesi yayımlamak istiyorsa, makalede kesinlikle "Risk of Hallucination Analysis" (Halüsinasyon Riski Analizi) başlıklı ayrıntılı bir bölüm bulunmak zorundadır.
DREAM Raporu ve güncel literatür standartlarına göre yapılması gereken değerlendirmeler şunlardır:

1. **Fiziksel Kalite Analizi (NPS ve MTF):** Üretilen görüntülerin Modülasyon Transfer Fonksiyonu (MTF) ve Gürültü Güç Spektrumu (NPS) analizleri yapılarak, sistemin frekans tepkisinin ve gürültü korelasyonlarının bozulmadığı, doku bütünlüğünün fiziksel yasalara uygun olduğu kanıtlanmalıdır.[35]
2. **Radyomik Özelliklerin (Radiomic Features) İstatistiksel Korunumu:** Yapay zeka modeli sadece gürültüyü azaltmakla kalmamalı, kanser tanısında kullanılan radyomik parametreleri (lezyonun şekli, hacmi, birinci dereceden doku istatistikleri, entropi) değiştirmemelidir. CT-Mamba çalışmasında olduğu gibi, NDCT (Yüksek Doz) görüntülerinden çıkarılan radyomik özellikler ile ağ tarafından üretilen denoised LDCT görüntülerinden çıkarılan radyomik özellikler arasında istatistiksel bir analiz (örneğin $p > 0.05$ ile anlamlı bir fark olmadığı) yapılarak modelin radyomik sadakati kanıtlanmalıdır.[11]
3. **Klinik Görev Odaklı Analiz (Task-Based Image Quality Approach):** Modelin başarısı, bir sonraki aşama olan klinik görevlerin performansı üzerinden ölçülmelidir. Örneğin, elde edilen gürültüsüz görüntüler standart bir akciğer nodülü tespit (Lung Nodule Detection) veya segmentasyon (örneğin Mask R-CNN veya U-Net) algoritmasına sokulmalı ve nodül tespit doğruluğunda (sensitivity, false-positive rate) veya Lung-RADS sınıflandırmasında

yaşanan artış/azalış raporlanmalıdır.[35]

4. **Dış Validasyon (External Cross-Validation) Zorunluluğu:** Modeli yalnızca çalışılan veri setinin %10'luk test grubunda doğrulamak yetersizdir. Orijinal bildiride bahsedilen "Antropomorfik Fantom" verisi gibi, farklı bir tarayıcı (scanner) cihazından, farklı enerji seviyesinden veya farklı bir hastaneden alınmış bağımsız bir veri seti üzerinde de (out-of-distribution) modelin aynı başarıyı gösterdiği ve yeni alanlarda (domain shift) halüsinasyon üretmediği kesin olarak kanıtlanmalıdır.[1]

Q1 Dergi Standartları İçin Yeniden Yapılandırılmış Kapsamlı Araştırma Yol Haritası

Yukarıdaki acımasız ve detaylı teknik analizler sonucunda, öğrencinin mevcut önerisinin ("U-Net'e CBAM eklemek ve standart DDPM ile kıyaslamak") IEEE TMI veya MedIA gibi zirve dergiler için yeterli özgünlüğe sahip olmadığı, ancak projenin çok daha yenilikçi bir düzleme çekilerek kurtarılabileceği açıkça görülmektedir. Öğrencinin veri ön işleme süreçlerini (DICOM işleme, -1000/1000 HU pencereleme, veri seti bölünmesi) tamamlamış olması ve GitHub üzerinde çalışan bir WGAN-GP altyapısına sahip olması [1] devasa bir mühendislik avantajıdır. Bu altyapı, eski nesil CBAM eklentileriyle harcanmamalı, doğrudan 2026'nın SOTA paradigmalarına entegre edilmelidir.
Bir akademik tez danışmanı perspektifiyle, mevcut projenin başarılı bir Q1 makalesine dönüştürülebilmesi için izlenmesi gereken stratejik, mimari ve metodolojik adımlar şu şekilde revize edilmelidir:

Faz 1: "State-Space GAN" veya "Mamba-WGAN" Mimarisinin Geliştirilmesi

Önerilen en radikal ve en yenilikçi adım, Pix2Pix altyapısındaki jeneratörü devrimsel bir şekilde değiştirmektir.

- **Mimari Müdahale:** Standart U-Net kodlayıcı-kod çözücü yapısındaki geleneksel evrişim (CNN) bloklarını tamamen terk edin veya zayıflatın. Bunun yerine, kodlayıcı ve kod çözücü arasındaki darboğaza (bottleneck) ve atlama bağlantılarına (skip connections), CT-Mamba ve DenoMamba çalışmalarında olduğu gibi **Visual Mamba (Durum Uzay Modeli)** blokları entegre edin.[11]
- **Özgünlük Gerekçesi:** Geliştirilecek bu yeni "Mamba-WGAN" hibrit mimarisi, Mamba'nın uzun menzilli bağlam yakalama yeteneğini (linear complexity ile) ve WGAN-GP'nin dağılımsal eşleştirme kararlılığını bir araya getiren literatürdeki en yenilikçi yapılardan biri olacaktır. Bu adım, makalenizi anında sıradan bir uygulama projesinden çıkarıp, mimari bir inovasyon makalesine dönüştürür.

Faz 2: Fizik Kılavuzlu (Physics-Guided) Gürültü Optimizasyonunun Entegrasyonu

GAN eğitimindeki kayıp fonksiyonlarını (Loss Functions) yalnızca matematiksel ve algısal

metriklerden çıkarıp fiziksel bir temele oturtun.

- **Metodolojik Geliştirme:** Jeneratörü eğitirken sadece L1 ve WGAN adversarial kaybını kullanmak yerine, literatürdeki son eğilimlere uygun olarak bir **Gürültü Güç Spektrumu (NPS) Kaybı** geliştirin ve ekleyin.[11] Bu kayıp terimi, ağın LDCT gürültüsünü temizlerken geride kalan doku hissiyatının NDCT'nin doğal fiziksel karakterine uymasını zorlayacaktır. Bu sayede radyologların eleştirdiği "plastik" görünümden kurtulursunuz. Nihai kayıp fonksiyonunuz şu şekilde yapılandırılmalıdır:

Faz 3: SOTA Difüzyon Modelleri ile "Verimlilik vs. Kalite" Ekseninde Akıllı Kıyaslama

Difüzyon modellerini rakip olarak konumlandırırken klasik DDPM'leri değil, alanın en güçlü modellerini hedef alın ve makalenin ana anlatısını "verimlilik" üzerine kurun.

- **Stratejik Yaklaşım:** Sıfırdan bir DDPM eğitmek yerine, literatürde yayınlanmış ve SOTA kabul edilen açık kaynaklı **CoreDiff** (IEEE TMI, 2024) [16] veya **FoundDiff** (2025) [20] modellerinin önceden eğitilmiş kodlarını referans (baseline) alın.
- **Ana İddia:** Makalenin temel argümanı şu olmalıdır: "Geliştirdiğimiz Mamba-WGAN mimarisi, görüntü kalitesi (PSNR, SSIM, LPIPS) ve yapısal doğruluk açısından güncel SOTA Difüzyon modelleri (CoreDiff) ile kafa kafaya rekabet ederken, difüzyonun binlerce iterasyon gerektiren hesaplama yükünü ortadan kaldırarak tek bir ileri geçişte (forward pass) çıkarım yapar ve 60 kat daha hızlı, gerçek zamanlı (real-time) klinik uygulamaya olanak tanır.".[17] Bu, hakemlerin asla reddedemeyeceği son derece güçlü ve rasyonel bir teknolojik savunmadır.

Faz 4: Acımasız Klinik ve Halüsinasyon Değerlendirmesi

Makalenin "Deneysel Sonuçlar" (Results) bölümünü, PSNR/SSIM tablolarından ibaret olmaktan çıkarıp tıbbi bir analiz raporuna dönüştürün.

- **DREAM Raporu Uyumluluğu:** 2025/2026 DREAM raporunu mutlaka atıf göstererek, modelinizin "Halüsinasyon Riski Analizini" sunun.[39] Orijinal görüntülerdeki küçük lezyonların ağ tarafından silinmediğini (false negative) ve sağlıklı dokulara sahte kalsifikasyonlar eklenmediğini (false positive) kanıtlamak için, radyolog okuma çalışmaları (reader studies) ile desteklenen istatistiksel analizler (Radyomik özellik korunum testleri - p değerleri) ekleyin.[11]
- **Dış Validasyon:** Modelinizin dayanıklılığını kanıtlamak için, modeli eğittiğiniz NIH-AAPM-Mayo veri seti dışında, bildiri metninizde yer alan Antropomorfik Fantom verilerinde [1] veya klinik akciğer tarama verilerinde test edin. Farklı tarayıcı donanımlarında da sistemin çökmediğini göstermek, algoritmanızın laboratuvardan kliniğe geçebileceğini ispatlar.

Sonuç

Mevcut EEMKON 2026 bildirisinin altyapısı, verilerin temizlenmesi ve temel GAN ardışık

düzeninin kurulması açısından öğrenciye mükemmel bir mühendislik pratiği sağlamıştır. Ancak, U-Net'e eski nesil bir CBAM yaması eklemek ve bunu 2020 standartlarındaki bir DDPM ile kıyaslamak, Q1 dergi dünyasında bilimsel bir ilerleme olarak değil, yalnızca teknolojik bir tekrarlama (incremental work) olarak görülecektir.
Mevcut kod ve veri avantajı; jeneratörün kalbine **Durum Uzay Modellerini (Mamba)** entegre etmeye, **Fizik-Kılavuzlu (NPS) kayıp optimizasyonları** kurgulamaya ve performansı basit pikseller yerine **klinik halüsinasyon analizleri ve radyomik sadakat (DREAM Raporu standartları)** üzerinden kanıtlamaya yönlendirilmelidir. Önerilen bu revize edilmiş stratejik yol haritası titizlikle uygulandığı takdirde, proje, salt bir teknoloji uygulamasından çıkıp, tıbbi yapay zeka alanındaki "çözünürlük, yapısal koruma, hesaplama hızı ve halüsinasyon güvenliği" darboğazlarına eşzamanlı çözüm üreten, referans gösterilecek, yüksek etkili ve tartışmasız şekilde yayınlanabilir (publishable) bir başyapıta dönüşecektir.

Alıntılanan çalışmalar

1. SerhanEge_CAYIRCI_EEMKON_Paper.pdf
2. deeplearning-note/GAN.md at master - GitHub, erişim tarihi Mart 14, 2026, https://github.com/hephaex/deeplearning-note/blob/master/GAN.md
3. Low-Dose CT Image Denoising Using a Generative Adversarial Network With Wasserstein Distance and Perceptual Loss - PubMed, erişim tarihi Mart 14, 2026, https://pubmed.ncbi.nlm.nih.gov/29870364/
4. [1708.00961] Low Dose CT Image Denoising Using a Generative Adversarial Network with Wasserstein Distance and Perceptual Loss - arXiv, erişim tarihi Mart 14, 2026, https://arxiv.org/abs/1708.00961
5. Low-Dose CT Image Denoising Combining U-Net Based on the CBAM Attention Mechanism with Generative Adversarial Networks - ResearchGate, erişim tarihi Mart 14, 2026, https://www.researchgate.net/publication/398713004_Low-Dose_CT_Image_Denoising_Combining_U-Net_Based_on_the_CBAM_Attention_Mechanism_with_Generative_Adversarial_Networks
6. Innovative Noise Extraction and Denoising in Low-Dose CT Using a Supervised Deep Learning Framework - MDPI, erişim tarihi Mart 14, 2026, https://www.mdpi.com/2079-9292/13/16/3184
7. High-Fidelity CT Image Denoising with De-TransGAN: A Transformer-Augmented GAN Framework with Attention Mechanisms - PMC, erişim tarihi Mart 14, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12729721/
8. High-Fidelity CT Image Denoising with De-TransGAN: A Transformer-Augmented GAN Framework with Attention Mechanisms - ResearchGate, erişim tarihi Mart 14, 2026, https://www.researchgate.net/publication/398592280_High-Fidelity_CT_Image_Denoising_with_De-TransGAN_A_Transformer-Augmented_GAN_Framework_with_Attention_Mechanisms
9. A NOVEL DEEP LEARNING MODEL, RDBCYCYLEGAN-CBAM FOR LOW-DOSE CT IMAGE DENOISING | bioRxiv, erişim tarihi Mart 14, 2026, https://www.biorxiv.org/content/10.64898/2026.02.17.706311.abstract

10. (PDF) A NOVEL DEEP LEARNING MODEL, RDBCYCYLEGAN-CBAM FOR LOW-DOSE CT IMAGE DENOISING - ResearchGate, erişim tarihi Mart 14, 2026, https://www.researchgate.net/publication/400940119_A_NOVEL_DEEP_LEARNING_MODEL_RDBCYCYLEGAN-CBAM_FOR_LOW-DOSE_CT_IMAGE_DENOISING
11. CT-Mamba: A hybrid convolutional State Space Model for low-dose ..., erişim tarihi Mart 14, 2026, https://pubmed.ncbi.nlm.nih.gov/40616952/
12. A new hybrid model for enhancing low-dose CT images using EfficientNetV2 and WGAN-GP, erişim tarihi Mart 14, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12802201/
13. Generative AI Models: A Comprehensive Review of GANs, Diffusion Models, and LLMs - International Journal of Scientific Research and Engineering Development, erişim tarihi Mart 14, 2026, https://ijsred.com/volume8/issue5/IJSRED-V8I5P157.pdf
14. Comparative Analysis of GANs and Diffusion Models in Image Generation - ResearchGate, erişim tarihi Mart 14, 2026, https://www.researchgate.net/publication/387444028_Comparative_Analysis_of_GANs_and_Diffusion_Models_in_Image_Generation
15. (PDF) Low-Dose CT Imaging Using a Regularization-Enhanced Efficient Diffusion Probabilistic Model - ResearchGate, erişim tarihi Mart 14, 2026, https://www.researchgate.net/publication/397935278_Low-Dose_CT_Imaging_Using_a_Regularization-Enhanced_Efficient_Diffusion_Probabilistic_Model
16. Top 424 IEEE Transactions on Medical Imaging papers published in 2024 - SciSpace, erişim tarihi Mart 14, 2026, https://scispace.com/journals/ieee-transactions-on-medical-imaging-3bsci4ra/2024
17. MAN: Latent Diffusion Enhanced Multistage Anti-Noise Network for Efficient and High-Quality Low-Dose CT Image Denoising - arXiv, erişim tarihi Mart 14, 2026, https://arxiv.org/html/2509.23603v1
18. Accelerating Diffusion: Task-Optimized latent diffusion models for rapid CT denoising, erişim tarihi Mart 14, 2026, https://snu.elsevierpure.com/en/publications/accelerating-diffusion-task-optimized-latent-diffusion-models-for/
19. CoreDiff: Contextual Error-Modulated Generalized Diffusion Model for Low-Dose CT Denoising and Generalization - IEEE Xplore, erişim tarihi Mart 14, 2026, https://ieeexplore.ieee.org/iel7/42/10419117/10268250.pdf
20. FoundDiff: Foundational Diffusion Model for Generalizable Low-Dose CT Denoising - arXiv, erişim tarihi Mart 14, 2026, https://arxiv.org/html/2508.17299v1
21. FoundDiff: Foundational Diffusion Model for Generalizable Low-Dose CT Denoising | Request PDF - ResearchGate, erişim tarihi Mart 14, 2026, https://www.researchgate.net/publication/394941576_FoundDiff_Foundational_Diffusion_Model_for_Generalizable_Low-Dose_CT_Denoising
22. PFCM: Poisson flow consistency models for low-dose CT image denoising - IEEE Xplore, erişim tarihi Mart 14, 2026, https://ieeexplore.ieee.org/iel8/42/4359023/10963840.pdf
23. Noise-Inspired Diffusion Model for Generalizable Low-Dose CT Reconstruction -

arXiv.org, erişim tarihi Mart 14, 2026, https://arxiv.org/html/2506.22012v1
24. Tackling Hallucination from Conditional Models for Medical Image Reconstruction with DynamicDPS | MICCAI 2025 - Open Access, erişim tarihi Mart 14, 2026, https://papers.miccai.org/miccai-2025/0899-Paper4526.html
25. Diffusion Transformer-to-Mamba Distillation for High-Resolution Image Generation - BMVA Archive, erişim tarihi Mart 14, 2026, https://bmva-archive.org.uk/bmvc/2025/assets/papers/Paper_931/paper.pdf
26. CVPR Poster GroupMamba: Efficient Group-Based Visual State Space Model, erişim tarihi Mart 14, 2026, https://cvpr.thecvf.com/virtual/2025/poster/33493
27. Mamba Technique: Adaptive State Space Models, erişim tarihi Mart 14, 2026, https://www.emergentmind.com/topics/mamba-technique
28. CT-Mamba: A Hybrid Convolutional State Space Model for Low-Dose CT Denoising, erişim tarihi Mart 14, 2026, https://arxiv.org/html/2411.07930v5
29. DenoMamba: A fused state-space model for low-dose CT denoising - PubMed, erişim tarihi Mart 14, 2026, https://pubmed.ncbi.nlm.nih.gov/41191471
30. DenoMamba: A fused state-space model for low-dose CT denoising - ResearchGate, erişim tarihi Mart 14, 2026, https://www.researchgate.net/publication/397321028_DenoMamba_A_fused_state-space_model_for_low-dose_CT_denoising
31. DenoMamba: A fused state-space model for low-dose CT denoising - ResearchGate, erişim tarihi Mart 14, 2026, https://www.researchgate.net/publication/384245618_DenoMamba_A_fused_state-space_model_for_low-dose_CT_denoising
32. DenoMamba: A fused state-space model for low-dose CT denoising - ICON LAB, erişim tarihi Mart 14, 2026, https://www.icon.bilkent.edu.tr/docs/Ozturk-2025-3.pdf
33. LangMamba: A Language-driven Mamba Framework for Low-dose CT Denoising with Vision-language Models - arXiv.org, erişim tarihi Mart 14, 2026, https://arxiv.org/html/2507.06140v1
34. FCDM: A Physics-Guided Bidirectional Frequency Aware Convolution and Diffusion-Based Model for Sinogram Inpainting - arXiv, erişim tarihi Mart 14, 2026, https://arxiv.org/html/2409.06714v6
35. sFRC for assessing hallucinations in medical image restoration - arXiv, erişim tarihi Mart 14, 2026, https://arxiv.org/html/2603.04673v1
36. A Review and Experimental Analysis of Denoising Techniques for Medical Images, erişim tarihi Mart 14, 2026, https://openneuroimagingjournal.com/VOLUME/18/ELOCATOR/e18744400404813
37. Metrics that Matter: Evaluating Image Quality Metrics for Medical Image Generation - arXiv, erişim tarihi Mart 14, 2026, https://arxiv.org/html/2505.07175v1
38. The Limits of Image Quality Measures in Healthcare, erişim tarihi Mart 14, 2026, https://healthmanagement.org/c/hospital/News/the-limits-of-image-quality-measures-in-healthcare
39. On Hallucinations in Artificial Intelligence–Generated Content for Nuclear Medicine Imaging (the DREAM Report) - PMC, erişim tarihi Mart 14, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12866389/

40. Evaluating the impact of deep learning-based image denoising on low-dose CT for lung cancer screening - PMC, erişim tarihi Mart 14, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12831282/